

Visualisation avec . Quelques exercices supplémentaires pour vous entraîner...

Dernière mise à jour : 29 sept. 2025

Sandrine LYSER

Exercice 1

– Manipulation des données –

En utilisant le jeu de données `hdv2003`, écrire dans un script les commandes qui permettent de répondre aux questions suivantes :

1. Quel est le nombre moyen de frères et soeurs des individus ?

On souhaite calculer cet indicateur sur l'ensemble de l'échantillon et pour chaque modalité de la pratique de la religion.

2. Quel est le nombre maximum d'heures passées devant la TV pour les individus qui sont à la retraite ?

On veut que le résultat affiche l'identifiant de ces individus, leur occupation antérieure et le nombre d'heures passées devant la TV.

3. Quel est le nombre total d'heures passées devant la TV par les étudiants/élèves ?

4. Quelles sont les valeurs minimales, médianes et maximales du nombre d'heures passées devant la TV par classe d'âge ?

On souhaite découper selon les classes d'âges suivantes : 18-24 ; 25-39 ; 40-54 ; 55-64 ; 65+.

La nouvelle variable "`cl_age`" doit être placée après la variable "`age`" dans un nouveau jeu de données qui s'appellera `hdv2003_m`.

Correction 1

Première étape : chargement des packages et des données

```
# Chargement des packages
library(dplyr)    # v1.1.4
library(tidyr)    # v1.3.1
library(ggplot2)  # v3.5.2
library(viridis)  # v0.6.5 # pour palette couleurs

# Chargement des données
data(hdv2003)
```

Question 1. Nombre moyen de frères et soeurs

```
# Pour l'ensemble des individus
hdv2003 |>
  summarise(FreresSoeurs_moyenne = mean(freres.soeurs, na.rm = TRUE))
```

```
FreresSoeurs_moyenne
1                3.283
```

```
# Pour chaque modalité de La pratique de la religion
hdv2003 |>
  group_by(relig) |> # pour faire le calcul pour chacune des modalités de la variable "relig"
  summarise(FreresSoeurs_moyenne = mean(freres.soeurs, na.rm = TRUE))
```

```
# A tibble: 6 x 2
  relig                FreresSoeurs_moyenne
  <fct>                <dbl>
1 Praticant regulier    4.07
2 Praticant occasionnel 3.34
3 Appartenance sans pratique 3.02
4 Ni croyance ni appartenance 3.14
5 Rejet                3.26
6 NSP ou NVPR          3.85
```

Question 2. Nombre maximum d'heures passées devant la TV pour les individus qui sont à la retraite

```
hdv2003 |>
  # sélection des individus qui sont à la retraite
  filter(occup == "Retraite") |>
  # sélection du nombre d'heures maximum pour ces individus
  filter(heures.tv == max(heures.tv, na.rm = TRUE)) |>
  # affichage des 3 variables : id, qualif et heures.tv
  select(id, qualif, heures.tv)
```

```
   id      qualif heures.tv
1 236  Ouvrier qualifie    10
2 421    Employe    10
3 426   Technicien    10
4 1075 Ouvrier qualifie    10
5 1538 Ouvrier qualifie    10
6 1621 Ouvrier qualifie    10
7 1727 Ouvrier specialise  10
```

Question 3. Nombre total total d'heures passées devant la TV des étudiants/élèves

```
hdv2003 |>
  filter(occup == "Etudiant, eleve") |>
  select(heures.tv) |>
  summarise(HeuresTV_total = sum(heures.tv))
```

```
HeuresTV_total
1             125
```

Question 4. Ajout de la variable "cl_age" dans un nouveau jeu de données nommé hdv2003_m et calcul des indicateurs par classes d'âge

```
# Création de la variable cl_age
hdv2003 |>
  mutate(cl_age = ifelse(age >= 18 & age <= 24, "18-24",
                        ifelse(age >= 25 & age <= 39, "25-39",
                              ifelse(age >= 40 & age <= 54, "40-54",
                                    ifelse(age >= 55 & age <= 64, "55-64",
                                          ifelse(age >= 65, "65+", "ERREUR")))))) |>
  relocate(cl_age, .after = age) -> hdv2003_m

# On obtient le même résultat en écrivant les commandes suivantes
hdv2003 |>
  mutate(cl_age = case_when(age >= 18 & age <= 24 ~ "18-24",
                           age >= 25 & age <= 39 ~ "25-39",
                           age >= 40 & age <= 54 ~ "40-54",
                           age >= 55 & age <= 64 ~ "55-64",
                           age >= 65 ~ "65+",
                           TRUE ~ "ERREUR")) |>
  relocate(cl_age, .before = sexe) -> hdv2003_m

# Indicateurs du nombre d'heures passées devant la TV par classe d'âge
hdv2003_m |>
  group_by(cl_age) |>
  summarise(Min = min(heures.tv, na.rm = TRUE),
            Mediane = median(heures.tv, na.rm = TRUE),
            Max = max(heures.tv, na.rm = TRUE))
```

```
# A tibble: 5 x 4
  cl_age    Min Mediane    Max
  <chr>    <dbl>    <dbl> <dbl>
1 18-24      0      2     10
2 25-39      0      2     11
3 40-54      0      2     11
4 55-64      0      2     12
5 65+        0      3     12
```

Exercice 2

– Représentations graphiques avec {ggplot2} –

On utilise pour cet exercice le jeu de données `hdv2003_m` auquel on va supprimer les observations qui ont une valeur manquante à la variable "heures.tv". Le nouveau jeu de données s'appellera `hdv2003_TVnarm`.

1. Représenter la distribution du nombre d'heures passées devant la TV en fonction de l'âge, sous forme de nuage de points.

2. Représenter la distribution du nombre d'heures passées devant la TV en fonction des classes d'âge, sous forme de boxplot.

Les *boxplot* auront une couleur différente selon les classes d'âge.

On utilisera une palette de couleurs adaptée aux variables catégorielles.

3. Représenter la distribution de la variable de satisfaction au travail, en excluant les non réponses à cette variable

a) pour faire une analyse globale

b) pour faire une analyse selon les classes d'âge, avec des barres de couleurs différentes selon la satisfaction au travail

Pour ces 2 graphiques, les modalités de la variable de satisfaction doivent être ordonnées : insatisfaction, équilibre, satisfaction.

4. Refaire le graphique 3b, en ne retenant que les individus pour lesquels le travail est aussi important que le reste.

Sur ce graphique, on veut représenter les pourcentages et non pas les effectifs.

Les graphiques doivent comporter les informations nécessaires à leur bonne compréhension : titres, labels, etc.


Correction 2

Étape préliminaire : suppression des observations pour lesquelles la valeur de "heures.tv" est manquante

```
hdv2003_m |>  
  drop_na(heures.tv) -> hdv2003_TVnarm
```


Question 1. Nuage de points

```
ggplot(data = hdv2003_TVnarm) +  
  geom_point(aes(x = age, y = heures.tv)) +  
  # informations  
  labs(x = "Age",  
        y = "Heures TV",  
        title = "Distribution du nombre d'heures passées devant la TV \n en fonction de l'âge.")
```



Question 2. Boxplot

```
ggplot(data = hdv2003_TVnarm) +  
  aes(x = cl_age, y = heures.tv, fill = cl_age) +  
  geom_boxplot() +  
  # palette couleurs Viridis  
  viridis::scale_fill_viridis(discrete = TRUE) +  
  # informations  
  labs(x = "Age",  
        y = "Heures TV",  
        title = "Distribution du nombre d'heures passées devant la TV \n en fonction des classes d'âge.")
```




Question 3. Barplot

Préparation des données : suppression des données manquantes à "trav.satisf" et ordre des modalités

```
hdv2003_TVnarm |>
  # suppression des valeurs manquantes
  drop_na(trav.satisf) |>
  # ordre des modalités
  mutate(trav.satisf0rdonne = factor(trav.satisf,
                                     levels = c("Insatisfaction", "Equilibre", "Satisfaction"))) |>
  relocate(trav.satisf0rdonne, .after = trav.satisf) -> hdv2003_TravSatisfnarm
```


Analyse globale

```
ggplot(data = hdv2003_TravSatisfnarm) +
  aes(x = trav.satisf0rdonne) +
  geom_bar() +
  # informations
  labs(x = "Satisfaction au travail",
       y = "Effectif",
       title = "Distribution de la variable de satisfaction au travail.")
```



Analyse selon les classes d'âge

```
ggplot(data = hdv2003_TravSatisfnarm) +  
  aes(x = trav.satisfOrdonne, fill = trav.satisfOrdonne) +  
  geom_bar() +  
  # graphique pour chaque modalité de cl_age  
  facet_grid(cols = vars(cl_age)) +  
  # choix des couleurs  
  scale_fill_manual(values = c("#D55E00", "#BDBDBD", "#009E73"),  
                    # modification du titre de la légende  
                    name = "Degré de satisfaction") +  
  
  # informations  
  labs(x = NULL,  
        y = "Effectif",  
        title = "Distribution de la variable de satisfaction au travail \n selon les classes d'âge.") +  
  # améliorations visuelles  
  theme(axis.text.x = element_blank(), # suppression des étiquettes de l'axe des abscisses  
        legend.position = "bottom") # positionnement de la légende sous le graphique
```




Question 4.

```
# Préparation des données
hdv2003_TravSatisfnarm |>
  # sélection des individus pour lesquels le travail est aussi important que le reste
  filter(trav.imp == "Aussi important que le reste") |>
  # sélection des variables à représenter sur le graphique
  select(cl_age, trav.satisfOrdonne) |>
  # calcul des pourcentages des modalités de trav.imp pour chaque classe d'âge
  tidyr::pivot_longer(cols = trav.satisfOrdonne,
                      names_to = "satisfaction",
                      values_to = "degre") |>

# groupes par classes d'âge
group_by(cl_age) |>
# calcul des effectifs de chaque degré de satisfaction par classe d'âge
dplyr::count(degre) |>
# calcul des pourcentages de chaque degré de satisfaction par classe d'âge
dplyr::mutate(pourcentage = n / sum(n) * 100) |>
# Graphique à partir des données préparées au-dessus
ggplot() +
  aes(x = degre, y = pourcentage, fill = degre) +
  geom_bar(stat = "identity") + # stat = "identity" car y précisé dans aes()
  # graphique pour chaque modalité de cl_age
  facet_grid(cols = vars(cl_age)) +
  # choix des couleurs
  scale_fill_manual(values = c("#D55E00", "#BDBDBD", "#009E73"),
                    # modification du titre de la légende
                    name = "Degré de satisfaction") +
  # graduations de l'axe des ordonnées
  scale_y_continuous(limits = c(0, 100), # valeurs min et max de l'axe
                     breaks = seq(from = 0, to = 100, by = 20)) + # graduations

# informations
labs(x = NULL,
     y = "Pourcentage",
     title = "Distribution de la variable de satisfaction au travail \n selon les classes d'âge.",
     caption = "Uniquement pour les individus pour lesquels
               le travail est aussi important que le reste") +
# améliorations visuelles
theme(axis.text.x = element_blank(), # suppression des étiquettes de l'axe des abscisses
      legend.position = "bottom") # positionnement de la légende sous le graphique
```

Distribution de la variable de satisfaction au travail
selon les classes d'âge.



Uniquement pour les individus pour lesquels
le travail est aussi important que le reste