

# Visualisation avec . Quelques exercices supplémentaires pour vous entraîner...

Dernière mise à jour : 29 sept. 2025

Sandrine LYSER

## Exercice 1

### – Manipulation des données –

En utilisant le jeu de données `hdv2003`, écrire dans un script les commandes qui permettent de répondre aux questions suivantes :

**1. Quel est le nombre moyen de frères et soeurs des individus ?**

On souhaite calculer cet indicateur sur l'ensemble de l'échantillon et pour chaque modalité de la pratique de la religion.

**2. Quel est le nombre maximum d'heures passées devant la TV pour les individus qui sont à la retraite ?**

On veut que le résultat affiche l'identifiant de ces individus, leur occupation antérieure et le nombre d'heures passées devant la TV\*.

**3. Quel est le nombre total d'heures passées devant la TV par les étudiants/élèves ?**

**4. Quelles sont les valeurs minimales, médianes et maximales du nombre d'heures passées devant la TV par classe d'âge ?**

On souhaite découper selon les classes d'âges suivantes : 18-24 ; 25-39 ; 40-54 ; 55-64 ; 65+.

La nouvelle variable "`cl_age`" doit être placée après la variable "`age`" dans un nouveau jeu de données qui s'appellera `hdv2003_m`.

# Correction 1

## Première étape : chargement des packages et des données

```
# Chargement des packages
library(dplyr)      # v1.1.4
library(tidyr)      # v1.3.1
library(ggplot2)    # v3.5.2
library(viridis)    # v0.6.5 # pour palette couleurs

# Chargement des données
data(hdv2003)
```

## Question 1. Nombre moyen de frères et soeurs

```
# Pour l'ensemble des individus
hdv2003 |>
  summarise(FreresSoeurs_moyenne = mean(freres.soeurs, na.rm = TRUE))
```

```
FreresSoeurs_moyenne
1                3.283
```

```
# Pour chaque modalité de La pratique de La religion
hdv2003 |>
  group_by(relig) |> # pour faire le calcul pour chacune des modalités de la variable "relig"
  summarise(FreresSoeurs_moyenne = mean(freres.soeurs, na.rm = TRUE))
```

```
# A tibble: 6 x 2
  relig                FreresSoeurs_moyenne
  <fct>                <dbl>
1 Praticant regulier    4.07
2 Praticant occasionnel 3.34
3 Appartenance sans pratique 3.02
4 Ni croyance ni appartenance 3.14
5 Rejet                3.26
6 NSP ou NVPR          3.85
```

## Question 2. Nombre maximum d'heures passées devant la TV pour les individus qui sont à la retraite

```
hdv2003 |>
  # sélection des individus qui sont à la retraite
  filter(occup == "Retraite") |>
  # sélection du nombre d'heures maximum pour ces individus
  filter(heures.tv == max(heures.tv, na.rm = TRUE)) |>
  # affichage des 3 variables : id, qualif et heures.tv
  select(id, qualif, heures.tv)
```

```
   id      qualif heures.tv
1 236  Ouvrier qualifie    10
2 421    Employe    10
3 426   Technicien    10
4 1075 Ouvrier qualifie    10
5 1538 Ouvrier qualifie    10
6 1621 Ouvrier qualifie    10
7 1727 Ouvrier specialise  10
```

### Question 3. Nombre total total d'heures passées devant la TV des étudiants/élèves

```
hdv2003 |>
  filter(occup == "Etudiant, eleve") |>
  select(heures.tv) |>
  summarise(HeuresTV_total = sum(heures.tv))
```

```
HeuresTV_total
1             125
```

### Question 4. Ajout de la variable "cl\_age" dans un nouveau jeu de données nommé hdv2003\_m et calcul des indicateurs par classes d'âge

```
# Création de la variable cl_age
hdv2003 |>
  mutate(cl_age = ifelse(age >= 18 & age <= 24, "18-24",
                        ifelse(age >= 25 & age <= 39, "25-39",
                              ifelse(age >= 40 & age <= 54, "40-54",
                                    ifelse(age >= 55 & age <= 64, "55-64",
                                          ifelse(age >= 65, "65+", "ERREUR")))))) |>
  relocate(cl_age, .after = age) -> hdv2003_m

# On obtient le même résultat en écrivant les commandes suivantes
hdv2003 |>
  mutate(cl_age = case_when(age >= 18 & age <= 24 ~ "18-24",
                           age >= 25 & age <= 39 ~ "25-39",
                           age >= 40 & age <= 54 ~ "40-54",
                           age >= 55 & age <= 64 ~ "55-64",
                           age >= 65 ~ "65+",
                           TRUE ~ "ERREUR")) |>
  relocate(cl_age, .before = sexe) -> hdv2003_m

# Indicateurs du nombre d'heures passées devant la TV par classe d'âge
hdv2003_m |>
  group_by(cl_age) |>
  summarise(Min = min(heures.tv, na.rm = TRUE),
            Mediane = median(heures.tv, na.rm = TRUE),
            Max = max(heures.tv, na.rm = TRUE))
```

```
# A tibble: 5 x 4
  cl_age    Min Mediane    Max
  <chr>    <dbl>    <dbl> <dbl>
1 18-24      0      2     10
2 25-39      0      2     11
3 40-54      0      2     11
4 55-64      0      2     12
5 65+        0      3     12
```

## Exercice 2

### – Représentations graphiques avec {ggplot2} –

On utilise pour cet exercice le jeu de données `hdv2003_m` auquel on va supprimer les observations qui ont une valeur manquante à la variable "heures.tv". Le nouveau jeu de données s'appellera `hdv2003_TVnarm`.

**1. Représenter la distribution du nombre d'heures passées devant la TV en fonction de l'âge, sous forme de nuage de points.**

**2. Représenter la distribution du nombre d'heures passées devant la TV en fonction des classes d'âge, sous forme de boxplot.**

Les *boxplot* auront une couleur différente selon les classes d'âge.

On utilisera une palette de couleurs adaptée aux variables catégorielles.

**3. Représenter la distribution de la variable de satisfaction au travail, en excluant les non réponses à cette variable**

a) pour faire une analyse globale

b) pour faire une analyse selon les classes d'âge, avec des barres de couleurs différentes selon la satisfaction au travail

Pour ces 2 graphiques, les modalités de la variable de satisfaction doivent être ordonnées : insatisfaction, équilibre, satisfaction.

**4. Refaire le graphique 3b, en ne retenant que les individus pour lesquels le travail est aussi important que le reste.**

Sur ce graphique, on veut représenter les pourcentages et non pas les effectifs.

**Les graphiques doivent comporter les informations nécessaires à leur bonne compréhension : titres, labels, etc.**


## Correction 2

Étape préliminaire : suppression des observations pour lesquelles la valeur de "heures.tv" est manquante

```
hdv2003_m |>
  drop_na(heures.tv) -> hdv2003_TVnarm
```


### Question 1. Nuage de points

```
ggplot(data = hdv2003_TVnarm) +
  geom_point(aes(x = age, y = heures.tv)) +
  # informations
  labs(x = "Age",
       y = "Heures TV",
       title = "Distribution du nombre d'heures passées devant la TV \n en fonction de l'âge.")
```



## Question 2. Boxplot

```
ggplot(data = hdv2003_TVnarm) +  
  aes(x = cl_age, y = heures.tv, fill = cl_age) +  
  geom_boxplot() +  
  # palette couleurs Viridis  
  viridis::scale_fill_viridis(discrete = TRUE) +  
  # informations  
  labs(x = "Age",  
        y = "Heures TV",  
        title = "Distribution du nombre d'heures passées devant la TV \n en fonction des classes d'âge.")
```




### Question 3. Barplot

Préparation des données : suppression des données manquantes à "trav.satisf" et ordre des modalités

```
hdv2003_TVnarm |>
  # suppression des valeurs manquantes
  drop_na(trav.satisf) |>
  # ordre des modalités
  mutate(trav.satisfOrdonne = factor(trav.satisf,
                                     levels = c("Insatisfaction", "Equilibre", "Satisfaction"))) |>
  relocate(trav.satisfOrdonne, .after = trav.satisf) -> hdv2003_TravSatisfnarm
```


### Analyse globale

```
ggplot(data = hdv2003_TravSatisfnarm) +
  aes(x = trav.satisfOrdonne) +
  geom_bar() +
  # informations
  labs(x = "Satisfaction au travail",
       y = "Effectif",
       title = "Distribution de la variable de satisfaction au travail.")
```



## Analyse selon les classes d'âge

```
ggplot(data = hdv2003_TravSatisfnarm) +  
  aes(x = trav.satisfOrdonne, fill = trav.satisfOrdonne) +  
  geom_bar() +  
  # graphique pour chaque modalité de cl_age  
  facet_grid(cols = vars(cl_age)) +  
  # choix des couleurs  
  scale_fill_manual(values = c("#D55E00", "#BDBDBD", "#009E73"),  
                    # modification du titre de la légende  
                    name = "Degré de satisfaction") +  
  # informations  
  labs(x = NULL,  
       y = "Effectif",  
       title = "Distribution de la variable de satisfaction au travail \n selon les classes d'âge.") +  
  # améliorations visuelles  
  theme(axis.text.x = element_blank(), # suppression des étiquettes de l'axe des abscisses  
        legend.position = "bottom") # positionnement de la légende sous le graphique
```






#### Question 4.

```
# Préparation des données
hdv2003_TravSatisfnarm |>
  # sélection des individus pour lesquels le travail est aussi important que le reste
  filter(trav.imp == "Aussi important que le reste") |>
  # sélection des variables à représenter sur le graphique
  select(cl_age, trav.satisfOrdonne) |>
  # calcul des pourcentages des modalités de trav.imp pour chaque classe d'âge
  tidyr::pivot_longer(cols = trav.satisfOrdonne,
                      names_to = "satisfaction",
                      values_to = "degre") |>

# groupes par classes d'âge
group_by(cl_age) |>
# calcul des effectifs de chaque degré de satisfaction par classe d'âge
dplyr::count(degre) |>
# calcul des pourcentages de chaque degré de satisfaction par classe d'âge
dplyr::mutate(pourcentage = n / sum(n) * 100) |>
# Graphique à partir des données préparées au-dessus
ggplot() +
  aes(x = degre, y = pourcentage, fill = degre) +
  geom_bar(stat = "identity") + # stat = "identity" car y précisé dans aes()
  # graphique pour chaque modalité de cl_age
  facet_grid(cols = vars(cl_age)) +
  # choix des couleurs
  scale_fill_manual(values = c("#D55E00", "#BDBDBD", "#009E73"),
                    # modification du titre de la légende
                    name = "Degré de satisfaction") +
  # graduations de l'axe des ordonnées
  scale_y_continuous(limits = c(0, 100), # valeurs min et max de l'axe
                    breaks = seq(from = 0, to = 100, by = 20)) + # graduations

# informations
labs(x = NULL,
     y = "Pourcentage",
     title = "Distribution de la variable de satisfaction au travail \n selon les classes d'âge.",
     caption = "Uniquement pour les individus pour lesquels
               le travail est aussi important que le reste") +
# améliorations visuelles
theme(axis.text.x = element_blank(), # suppression des étiquettes de l'axe des abscisses
      legend.position = "bottom") # positionnement de la légende sous le graphique
```

Distribution de la variable de satisfaction au travail  
selon les classes d'âge.



Uniquement pour les individus pour lesquels  
le travail est aussi important que le reste