

Visualisation avec . Mini projet - Éléments de correction

Dernière mise à jour : 07 oct. 2026

Sandrine LYSER

Table des matières

1	Création du projet	2
2	Nettoyer et préparer les données - le script 01_nettoyage.R	2
3	Analyse exploratoire - le script '02_analyse.R	5

1 Création du projet

Le projet `exploration_data` est organisé de la façon suivante. Cette organisation est le contenu du fichier `README.md`

```
exploration_data/
├── data/
│   └── vico2020.csv
├── scripts/
│   ├── 01_nettoyage.R
│   └── 02_analyse.R
├── outputs/
│   ├── fig01_distribution_age.png
│   ├── fig02_relation_age_revenus.png
│   ├── fig03_comparaison_temps_sexe.png
│   └── fig04_contacts_situation.png
├── docs/
│   └── README.md
└── exploration_data.Rproj
```

Le dossier

- `data/` contient les données source (fichier `vico2020.csv`)
- `scripts/` est vide à la création du projet mais contiendra les deux scripts demandés pour cet exercice, qui apparaissent donc dans le schéma
- `outputs/` est vide à l'initialisation du projet mais contiendra ensuite les différents graphiques produits dans l'analyse et qui sont listés ici
- `docs/` peut contenir la documentation du projet, le dictionnaire des variables, les consignes ou un compte rendu

2 Nettoyer et préparer les données - le script `01_nettoyage.R`

```
#
# Script: Import et nettoyage/préparation des données vico2020
# Author: Sandrine.Lyser
# Créé Le : 2026-10-07
# Dernière modification : 2026-10-07
# Text default encoding : UTF-8
# R version 4.6.0 (2026-04-24 ucrt) -- "Because it was There"
#

#
# Packages #####
library(readr)      # v 2.2.0
library(dplyr)      # v 1.2.1
library(questionr)  # v 0.8.2

#
# Import des données #####

# Les données sont au format csv. Les colonnes sont séparées par un ";". Le séparateur des
↪ décimales est la ",". On peut utiliser la fonction read_csv2() du package readr qui est
↪ paramétrée avec ces séparateurs

readr::read_csv2("data/vico2020.csv") -> vico2020_src
```

```
#
# Aperçu de la structure des données #####
```

```
str(vico2020_src)
```

```
spc_tbl_ [2,000 x 20] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ ID      : num [1:2000] 1 2 3 4 5 6 7 8 9 10 ...
 $ SEXE    : chr [1:2000] "Une femme" "Une femme" "Une femme" "Une femme" ...
 $ AGE     : num [1:2000] 30 30 24 45 57 35 35 36 21 64 ...
 $ SITCONJ : chr [1:2000] "Non" "Non" "Non" "Oui" ...
 $ RESNB   : num [1:2000] 1 5 2 2 1 4 2 2 1 1 ...
 $ RESISOL : chr [1:2000] "Oui, autant que je voulais" "Oui, mais pas autant que je voulais" "Oui, autant q
 $ LOGAUTRE : chr [1:2000] "Non, je suis toujours dans mon logement habituel." "Non, je suis toujours dans m
 $ MASQUE   : chr [1:2000] "Non sélectionné" "Non sélectionné" "Oui" "Non sélectionné" ...
 $ TEMPS    : chr [1:2000] "Non, je ne manque pas du tout de temps libre" "Oui, je manque un peu de temps l
 $ INQUIET  : chr [1:2000] "Non sélectionné" "Oui" "Non sélectionné" "Non sélectionné" ...
 $ VOISINS  : chr [1:2000] "Non sélectionné" "Oui" "Non sélectionné" "Non sélectionné" ...
 $ CONTROL  : chr [1:2000] "Non, jamais" "Oui, une seule fois" "Non, jamais" "Non, jamais" ...
 $ AMIS     : chr [1:2000] "Ni plus ni moins" "Moins souvent" "Plus souvent" "Plus souvent" ...
 $ FAMILLE  : chr [1:2000] "Plus souvent" "Plus souvent" "Ni plus ni moins" "Plus souvent" ...
 $ POL      : chr [1:2000] "Je ne me retrouve pas dans ces catégories" "Au centre" "A gauche" "A gauche" ..
 $ DIPLOIV  : chr [1:2000] "Un diplôme universitaire correspondant à plus de 4 années d'études supérieures a
 $ SITPROF_rec: chr [1:2000] "A la recherche d'un emploi" "En études" "A la recherche d'un emploi" "En emploi
 $ PCS_rec6  : chr [1:2000] "Cadres et professions intellectuelles supérieures" "Cadres et professions intell
 $ REV      : chr [1:2000] "Moins de 800 euros par mois" "Moins de 800 euros par mois" "6000 euros par mois
 $ POIDS_init : num [1:2000] 0.234 0.745 0.231 0.562 0.206 ...
- attr(*, "spec")=
 .. cols(
 .. ID = col_double(),
 .. SEXE = col_character(),
 .. AGE = col_double(),
 .. SITCONJ = col_character(),
 .. RESNB = col_double(),
 .. RESISOL = col_character(),
 .. LOGAUTRE = col_character(),
 .. MASQUE = col_character(),
 .. TEMPS = col_character(),
 .. INQUIET = col_character(),
 .. VOISINS = col_character(),
 .. CONTROL = col_character(),
 .. AMIS = col_character(),
 .. FAMILLE = col_character(),
 .. POL = col_character(),
 .. DIPLOIV = col_character(),
 .. SITPROF_rec = col_character(),
 .. PCS_rec6 = col_character(),
 .. REV = col_character(),
 .. POIDS_init = col_double()
 .. )
- attr(*, "problems")=<pointer: 0x00000176f5afccf0>
```

```
# Le jeu de données contient 2000 observations et 20 variables.
# Les variables MASQUE, INQUIET et VOISINS ne sont pas suffisamment renseignées pour
  ↪ pouvoir être analysées car elles ne contiennent que deux modalités "Non sélectionné" et
  ↪ "Oui" et n'auront donc pas d'utilité dans l'analyse.
# Ces variables sont supprimées du jeu de données.
```

```
#
# Nettoyage des données #####
```

```
## .....
## Suppression de variables insuffisamment renseignées #####
vico2020_src |>
  select(-c(MASQUE, INQUIET, VOISINS)) -> vico2020

## .....
## Harmonisation du nom des variables (convention 'underscore_separated') #####
vico2020 |>
  rename(SIT_CONJ = SITCONJ,
         RES_NB = RESNB,
         RES_ISOL = RESISOL,
         LOG_AUTRE = LOGAUTRE,
         DIPLO_NIV = DIPLO_NIV) -> vico2020

# On peut vérifier les modifications en affichant le nom des variables de vico2020
vico2020 |>
  names()
```

```
[1] "ID"          "SEXE"        "AGE"         "SIT_CONJ"    "RES_NB"
[6] "RES_ISOL"    "LOG_AUTRE"   "TEMPS"       "CONTROL"     "AMIS"
[11] "FAMILLE"     "POL"         "DIPLO_NIV"   "SITPROF_rec" "PCS_rec6"
[16] "REV"         "POIDS_init"
```

```
## .....
## Création de la variable AGE_CL pour les classes d'âge #####
vico2020 |>
  mutate(AGE_CL = case_when(AGE <= 19 ~ "0-19 ans",
                           AGE >= 20 & AGE <= 39 ~ "20-39 ans",
                           AGE >= 40 & AGE <= 59 ~ "40-59 ans",
                           AGE >= 60 & AGE <= 74 ~ "60-74 ans",
                           AGE >= 75 ~ "75 ans et plus",
                           TRUE ~ "ERREUR")) |>

  # repositionnement de la variable AGE_CL après AGE
  relocate(AGE_CL, .after = AGE) -> vico2020

# On peut vérifier la création de cette variable
# - en affichant ses modalités
vico2020 |>
  distinct(AGE_CL)
```

```
# A tibble: 4 x 1
```

```
AGE_CL
<chr>
1 20-39 ans
2 40-59 ans
3 60-74 ans
4 0-19 ans
```

```
# - en affichant sa distribution, avec la fonction freq du package questionr par ex.
vico2020 |>
  select(AGE_CL) |>
  questionr::freq(total = TRUE)
```

	n	%	val%
0-19 ans	22	1.1	1.1
20-39 ans	783	39.1	39.1
40-59 ans	826	41.3	41.3
60-74 ans	369	18.4	18.4
Total	2000	100.0	100.0

3 Analyse exploratoire - le script '02_analyse.R

```
#
# Script: Analyse exploratoire des données vico2020
# Author: Sandrine.Lyser
# Créé Le : 2026-10-07
# Dernière modification : 2026-10-07
# Text default encoding : UTF-8
# R version 4.6.0 (2026-04-24 ucrt) -- "Because it was There"
#


#
# Packages #####
library(ggplot2) # v 4.0.3
library(ggstats) # v 0.13.0 #pour "prop" dans Les graphiques

#
# Création d'un thème personnalisé pour Les graphiques ggplot2 #####
theme_vico <- function(){
  # On part du thème "gray" avec une taille de police de 14
  theme_gray(base_size = 14) +
  # Mise en forme du titre : police en gras, de taille 16 et de couleur verte
  theme(plot.title = element_text(face = "bold",
                                   size = unit(16, "pt"),
                                   color = "#2E3A1B"),
        # Mise en forme de la Légende : en gris, italique et de taille 10, et aligné à droite
        plot.caption = element_text(color = "grey40",
                                     face = "italic",
                                     size = unit(10, "pt"),
                                     hjust = 1),
        # Mise en forme des Labels des axes : en gras
        axis.title = element_text(face = "bold"),
        # Emplacement de la Légende : sous Le graphique
        legend.position = "bottom",
        # Grille principale : ligne en pointillés, de couleur gris clair
        panel.grid.major = element_line(color = "grey80",
                                         linetype = "dashed"))
}

#
# Graphiques #####

## .....
## Graphique 1 : distribution de la variable AGE #####
ggplot(data = vico2020) +
  # variable représentée
  aes(x = AGE) +
  # type de graphique
  geom_histogram(bins = 5,
                 color = "white",
                 fill = "#2E3A1B") +
  # informations sur Les données
  labs(title = "Distribution de l'âge",
        x = "Âge en 2020",
        caption = "Source : enquête VICO 2020") +
  # application du thème personnalisé
  theme_vico()
```

Distribution de l'âge




Source : enquête VICO 2020

```
# Export du graphique au format image
ggsave(filename = "outputs/histo_AGE.png")

## .....
## Graphique 2 : vie en couple selon les classes d'âge #####
ggplot(data = vico2020) +
  # variable représentée
  aes(x = SIT_CONJ) +
  # type de graphique
  geom_bar(color = "white",
           fill = "#2E3A1B") +
  # comparaison selon les classes d'âge (il n'y a pas de 75 ans et plus)
  # 4 graphiques disposés en colonnes
  facet_grid(cols = vars(AGE_CL)) +
  # informations sur les données
  labs(title = "Vie en couple selon les classes d'âge",
       x = "Vie en couple",
       caption = "Source : enquête VICO 2020") +
  # application du thème personnalisé
  theme_vico()
```

Vie en couple selon les classes d'âge




Source : enquête VICO 2020

```
# Export du graphique au format image
ggsave(filename = "outputs/barplot_SIT_CONJ_facet_AGE_CL.png")

# Il serait possible d'améliorer ce graphique pour le rendre interprétable
# - en supprimant les non-réponses à SIT_CONJ
# - en représentant les proportions plutôt que les effectifs
ggplot(data = vico2020 |>
  # filtre pour supprimer les réponses manquantes à SIT_CONJ
  filter(!is.na(SIT_CONJ))) +
# variable représentée
aes(x = SIT_CONJ,
  # calcul des proportions, par classes d'âge
  by = AGE_CL,
  y = ggplot2::after_stat(prop),
  # couleur de remplissage des barres selon SIT_CONJ
  fill = SIT_CONJ) +
# type de graphique
geom_bar(stat = "prop", # afficher les proportions
  color = "white") +
# comparaison selon les classes d'âge (il n'y a pas de 75 ans et plus)
# 4 graphiques disposés en colonnes
facet_grid(cols = vars(AGE_CL)) +
# affichage de l'axe des ordonnées en pourcentages
scale_y_continuous(labels = scales::percent,
  limits = c(0, 1)) + # échelle : 0 à 100
# couleurs des barres : vert pour 'Oui' et rouge pour 'Non'
scale_fill_manual(values = c("Oui" = "lightgreen",
  "Non" = "red")) +
# informations sur les données
labs(title = "Vie en couple selon les classes d'âge",
  x = "Vie en couple",
  y = "Pourcentages",
  caption = "Source : enquête VICO 2020") +
# application du thème personnalisé
theme_vico() +
```

```
theme(legend.position = "none") # suppression de La Légende
```

Vie en couple selon les classes d'âge



Source : enquête VICO 2020