

Visualisation avec

Dernière mise à jour : 02 oct. 2026

Sandrine LYSER

Table des matières

Présentation du cours	2
Objectifs pédagogiques	2
Organisation des séances	2
Évaluation finale	2
1 Séance 1. R et RStudio, bonnes pratiques pour une analyse reproductible : du projet au tidyverse	3
1.1 Objectifs pédagogiques	3
1.2 La reproductibilité	3
1.2.1 Pourquoi parler de reproductibilité ?	3
1.2.2 Qu'est-ce qu'une analyse reproductible ?	3
1.2.3 Que se passe-t'il sans "bonnes" pratiques ?	3
1.2.4 De la donnée au résultat : une chaîne de travail transparente et documentée	4
1.3 Comment travailler de façon reproductible avec R/RStudio ?	4
1.3.1 Les projets RStudio	4
1.3.2 Les scripts R	6
1.3.3 Le fichier README	8
1.3.4 Citer la version de R ainsi que les packages que vous avez utilisés dans vos travaux	9
1.4 À VOUS DE JOUER !	10
1.5 L'univers du tidyverse	11
1.5.1 Présentation générale et installation	11
1.6 Manipulations des données	12
1.6.1 Import/Export des données	12
1.6.2 Manipulations sur les observations et les variables avec le package [dplyr]	14
1.7 À VOUS DE JOUER !	19
2 Séance 2. Premiers graphiques avec [ggplot2]	20
2.1 Objectifs pédagogiques	20
2.2 Visualisations graphiques avec [ggplot2]	20
2.2.1 Le package [ggplot2]	20
2.2.2 La grammaire ggplot	20
2.2.3 Construction d'un graphique, couche par couche	21
2.2.4 Éléments de personnalisation des graphiques pour faciliter leur lecture	25
2.2.5 Exemples de graphiques de base avec [ggplot2]	27
2.2.6 Exemple de mise en forme plus avancée d'un graphique avec [ggplot2]	30
2.2.7 Sauvegarde des graphiques créés avec [ggplot2]	31
2.2.8 Vous n'êtes pas à l'aise pour réaliser un graphique [ggplot2] ?	31
2.2.9 Un site pour aider à trouver la représentation la plus appropriée aux données	32
2.3 À VOUS DE JOUER !	32
3 Bibliographie	33

Présentation du cours

Objectifs pédagogiques

Dans ce cours, vous apprendrez à...

- utiliser R sous RStudio en utilisant les projets RStudio
- travailler de manière **reproductible**, en organisant votre travail et en structurant vos scripts
- utiliser les principaux outils du **tidyverse** pour manipuler et visualiser des données
- produire des visualisations de données sous forme de graphiques de qualité, en utilisant [ggplot2](#)

Organisation des séances

1. Vendredi 02 octobre 2026 (3h)
R et RStudio, bonnes pratiques pour une analyse reproductible : du projet au **tidyverse**
2. Lundi 05 octobre 2026 (2h30)
Premiers graphiques [ggplot2](#)
Transformation des données et approfondissements [ggplot2](#)
3. Vendredi 09 octobre 2026 (4h30)
Visualisations avancées
4. Vendredi 02 novembre (2h)
Évaluation finale (1h30)
Débriefing évaluation et cours

Évaluation finale

Format pratique sur ordinateur pour évaluer

- l'organisation du code
- la pertinence graphique
- la bonne utilisation du **tidyverse**
- la clarté/reproductibilité du script

📊 Données utilisées dans les exemples

Les exemples du cours s'appuient sur le jeu de données **Journals**, disponible dans le package `[Ecdat]`

Ce jeu de données se compose de 180 observations décrites par 10 variables

- **title** : titre de la revue
- **pub** : éditeur
- **society** : société
- **libprice** : prix de l'abonnement
- **pages** : nombre de pages
- **charpp** : nombre de caractères par page
- **citestot** : nombre total de citations
- **date1** : année de création de la revue
- **oclc** : nombre d'abonnements
- **field** : domaine de la revue

📊 Données utilisées dans les exercices

Les exercices se feront sur le jeu de données fictives **communes**, disponible dans l'espace elearn

1 Séance 1. R et RStudio, bonnes pratiques pour une analyse reproductible : du projet au tidyverse

1.1 Objectifs pédagogiques

À l'issue de cette séance, vous serez capable de

- comprendre ce qu'est la reproductibilité
- de mettre en oeuvre de "bonnes" pratiques sous R/RStudio pour répondre aux enjeux de reproductibilité
- créer et organiser un projet RStudio, en structurant vos scripts
- importer un jeu de données
- effectuer les premières manipulations et transformations sur les données avec le package {dplyr}

1.2 La reproductibilité

1.2.1 Pourquoi parler de reproductibilité?

Une analyse ne se résume pas à son résultat, celui-ci doit pouvoir être

- compris
- vérifié
- réexécuté
- corrigé
- mis à jour
- partagé avec d'autres personnes

1.2.2 Qu'est-ce qu'une analyse reproductible?

Une analyse est dite **reproductible** lorsque l'on peut obtenir les mêmes résultats en utilisant

- les mêmes données en entrée
- les mêmes méthodes
- les mêmes étapes de calcul
- le même code

La reproductibilité est un processus qui peut être reproduit par une autre personne et/ou à partir des mêmes données et qui permet d'expliquer et partager son travail

i Reproductibilité ? Réplicabilité ?

Deux notions à distinguer

- **reproductibilité** : en utilisant le même code et les mêmes données , on retrouve le même résultat (valeur numérique, tableau, graphique, etc.)
- **réplicabilité** : en appliquant la même démarche, sur de nouvelles données, on obtient des résultats comparables

1.2.3 Que se passe-t'il sans "bonnes" pratiques?


- Des résultats impossibles à retrouver
- Des chemins de fichiers propres à l'ordinateur de l'auteur
- Des modifications manuelles sur le fichier de données non documentées
- Des commandes exécutées dans la console qui ne figurent pas dans le script
- Des erreurs de copier-coller ou des résultats copiés manuellement dans un rapport
- Des versions différentes de R ou des packages
- Des difficultés pour identifier les packages utilisés
- Des difficultés à transmettre ou à reprendre un travail plusieurs mois plus tard

❗ Ces problèmes sont souvent liés à l'organisation du travail

➤ Trois grands principes à respecter pour éviter ces erreurs (Orozco et al., 2020)

- Organiser son travail
- Coder pour les autres
- Automatiser le plus possible

1.2.4 De la donnée au résultat : une chaîne de travail transparente et documentée



À chaque étape, il faut pouvoir répondre à trois questions

1. Qu'a-t-on fait ?
2. Pourquoi l'a-t-on fait ?
3. Peut-on refaire cette étape ?

» Chaque opération doit être identifiable, justifiée et réexécutable

La reproductibilité repose sur la conservation

- des données
- du flux de traitement (scripts d'importation et de traitement, fonctions, méthodes statistiques utilisées)
- de la documentation (métadonnées, dictionnaire des variables, version de R et des packages, instructions pour relancer l'analyse)
- des informations nécessaires à l'interprétation (tableaux, graphiques)

1.3 Comment travailler de façon reproductible avec R/RStudio ?

1.3.1 Les projets RStudio

Les projets RStudio sont utiles pour

- **organiser plus facilement son travail** : 1 projet = 1 étude
 - » environnement isolé, pas de conflits entre projets
- **regrouper dans un même dossier tous les scripts** : scripts R/quarto, fonctions, données, résultats, graphiques, etc.
- **améliorer la portabilité et faciliter les collaborations** : utilisation des chemins de fichiers relatifs
 - » reproductibilité facilitée


i Chemins absolus/relatifs

- Le chemin absolu est exprimé par rapport au disque dur, à l'ordinateur
Exemple : C:/Users/...
- Le chemin relatif est exprimé par rapport au projet
Exemple : data/mon_fichier.csv

💡 Le répertoire par défaut du projet est le dossier où est enregistré le projet sur votre machine


1.3.1.1 Comment créer un projet?

À partir de l'icône dédiée en haut à droite de RStudio



Cliquez sur **New Project > New Directory > New Project** et complétez les informations requises

- le nom du dossier/projet
- son emplacement (dossier de votre choix)



Quand le projet est créé

- RStudio redémarre et se place dans ce projet
- le projet apparaît dans l'onglet *Files* de RStudio



Pour ranger efficacement les différents documents liés à l'analyse, vous pouvez créer les sous-dossiers

- soit en cliquant sur **New Folder** dans le menu en haut de l'onglet *Files*
- soit de façon classique, à partir de l'explorateur de fichier de votre machine


1.3.1.2 Comment structurer ses projets?

Choisissez la structuration qui vous correspond le mieux et qui permet

- de **rassembler** tous les éléments liés au projet dans un seul dossier
- de **structurer** en dossiers/sous-dossiers pour séparer données source/créées, scripts, documentation, résultats, etc.



Les données initiales et les scripts de traitement sont les plus importants



```
name_of_project
|--data
|  |--2017report.csv
|  |--2016report.pdf
|  |--summary2016_2017.csv
|--docs
|  |--01-analysis.Rmd
|  |--01-analysis.html
|--scripts
|  |--exploratory_analysis.R
|  |--pdf_scraper.R
|--name_of_project.Rproj
|--run_all.R
```

```
name_of_project
|--raw_data
|  |--WhateverData.xlsx
|  |--2017report.csv
|  |--2016report.pdf
|--output_data
|  |--summary2016_2017.csv
|--rmd
|  |--01-analysis.Rmd
|--docs
|  |--01-analysis.html
|  |--01-analysis.pdf
|  |--02-deeper.html
|  |--02-deeper.pdf
|--scripts
|  |--exploratory_analysis.R
|  |--pdf_scraper.R
|--name_of_project.Rproj
|--run_all.R
```

Exemples de structuration de projets R Source (figures 2 & 3) : <https://learn.r-journalism.com/en/publishing/workflow/r-projects/> - Dernier accès : 2026-09-08

1.3.2 Les scripts R

- Ils permettent de **garder la trace** du processus de création de chaque variable, tableau, figure, etc., ce qui permet de refaire les traitements dans leur globalité
- Ils sont **facilement partageables** avec d'autres, sous réserve de respecter des pratiques de "bon" usage
 - coder de façon compréhensible avec des commentaires et en documentant ses fonctions
 - donner des noms explicites aux objets et fonctions
 - utiliser les conventions de nommage, notamment pour distinguer les variables d'origine des variables créées



- Pour les **variables**, utiliser un **nom**
Exemple : temperature_max
- Pour les **fonctions**, utiliser un **verbe**
Exemple : create.map serait une fonction qui permettrait de créer une carte
- Pour **distinguer variables d'origine / variables recodées**, on peut utiliser un préfixe ou un suffixe
Exemple : age est la variable d'origine et age_recod est la variable recodée

i Les conventions de nommage

Il existe différentes conventions

- **alllowercase** : tout en minuscule, sans séparateur
- **period.separated** : tout en minuscule, mots séparés par des points
- **underscore_separated** : tout en minuscule, mots séparés par un *underscore* (`_`)
- **lowerCamelCase** : première lettre des mots en majuscule, à l'exception du premier mot; et si nom simple, tout en minuscule
- **UpperCamelCase** : première lettre des mots en majuscule, y compris le premier et même lorsque le nom est composé d'un seul mot

💡 Possibilité de mixer les conventions mais en gardant une cohérence afin de faciliter la compréhension des fichiers et du code

⚠ R est sensible à la casse ce qui signifie que variable et Variable sont deux objets différents

1.3.2.1 Comment organiser ses scripts ?

- Utiliser une **convention de dénomination des fichiers** et donner des **noms explicites**
- **Séparer les traitements**
 - import et préparation des données (nettoyage, fusion, filtrage)
 - traitement statistique
 - analyses univariées
 - analyses bivariées
 - analyses multivariées/modélisation
 - production des résultats, rapports

💡 Comment nommer ses scripts ?


- Une "bonne" pratique consiste à utiliser la structure `numero_nom_millesime.extension`
- Le nom ne doit contenir ni caractères spéciaux ('-..,;:\/\$^') ni caractères accentués
Exemple : `01_import_donnees_20250606.R`; `02_nettoyage_donnees_20250610.R`;
`03_analyses_univariees_20250701.R`

i Ressources sur le processus d'analyse et de communication des données reproductibles

-  [R Workflow](#)
-  [Reproducible analytical pipeline](#)

1.3.2.2 Comment structurer ses scripts ?

1. Commencer l'écriture du script par les **métadonnées** (titre, auteur, date, version de R, encodage, etc.)



```
1 # ...
2 # ---Script: ---
3 # ---Author: ---
4 # ---Créé le : ---
5 # ---Dernière modification : ---
6 # ---Text default encoding : UTF-8 ---
7 # ---R version 4.2.1 (2022-06-23 ucrt) --- "Funny-Looking Kid"---
8 # ...
```

2. Lister les **packages** utilisés, au début des scripts, pour les identifier plus rapidement, en notant leur version

- manuellement

```
library(tidyverse)    # v2.0.0
library(questionr)    # v0.8.2
```

- de façon automatisée

```
packages_utilises <- sessionInfo()
```

3. **Structurer** en parties et sous-parties, facilement grâce à l'*addin strcode*

```
# -----
# Titre 1 #####
```

```
## .....
## Titre 2 #####
```

🔧 *Installation : `remotes::install_github("Lorenzwalther/strcode")`*

4. **Commenter** les scripts, en particulier pour expliquer les étapes-clés (= une aide pour les autres, mais aussi pour soi, pour plus tard)

i Le préfixage

La notation

```
dplyr::filter(Journals, field == "Econometrics")
```

peut remplacer le code

```
library(dplyr)
filter(Journals, field == "Econometrics")
```

Avantages

- Évite les conflits si plusieurs packages ont une fonction avec le même nom (mais des paramètres différents)
Exemple : la fonction `filter()` existe dans les packages `[stats]` et `[dplyr]`
- Identifie le package d'où provient une fonction
- Ne charge pas la totalité d'un package pour n'utiliser qu'une seule de ses fonctions

💡 Aide pour écrire les scripts

🔧 Activer les options de diagnostic pour signaler les erreurs dans les scripts sous RStudio : **Tools > Global Options > Code > Diagnostics**

```
13 -
14 # -
15 # Packages ..... #####
16 library(tidyverse) ... # v1.3.2
17 -
```

🔧 package `[styler]` : mettre en forme le code selon le [Tidyverse Style Guide](#) (ou selon son propre style)

🔧 package `[lintr]` : vérifier que le code est conforme à un guide de style donné

1.3.3 Le fichier README

Ce fichier, généralement un fichier au format `.txt` ou `.md` (markdown), qui présente le **projet**, sa **structuration** et les **étapes d'exécution des différents script** pour comprendre, reproduire et utiliser le projet, est à placer dans le dossier du projet

Exemple de fichier README

```
# VisuR_2026
```

Projet du cours "Visualisation des données sous R" pour l'année universitaire 2026-2027

```
## Structure
```

```
- data/ : données
```

```

├─ sources/ : données sources, données brutes
├─ produites/ : données produites
- scripts/ : scripts R, qmd
- outputs/ : graphiques et tableaux exportés
- docs/ : rapports et supports

## Comment reproduire les analyses
1. Ouvrir le projet `VisuR_2026.Rproj`
2. Exécuter les scripts dans l'ordre (01_import.R, 02_nettoyage.R, etc.)
3. Les graphiques générés sont enregistrés dans le dossier outputs
4. Le rapport d'étude est enregistré dans le dossier docs

```

1.3.4 Citer la version de R ainsi que les packages que vous avez utilisés dans vos travaux

Avec la fonction `citation()`

1.3.4.1 Pour citer la version de R

```

# Citer R
citation()

```

To cite R in publications use:

R Core Team (2026). *_R: A Language and Environment for Statistical Computing_*. R Foundation for Statistical Computing, Vienna, Austria.
doi:10.32614/R.manuals <<https://doi.org/10.32614/R.manuals>>.
<<https://www.R-project.org/>>.

Une entrée BibTeX pour les utilisateurs LaTeX est

```

@Manual{,
  title = {R: A Language and Environment for Statistical Computing},
  author = {{R Core Team}},
  organization = {R Foundation for Statistical Computing},
  address = {Vienna, Austria},
  year = {2026},
  doi = {10.32614/R.manuals},
  url = {https://www.R-project.org/},
}

```

We have invested a lot of time and effort in creating R, please cite it when using it for data analysis. See also '`citation("pkgname")`' for citing R packages.

1.3.4.2 Pour citer un package

```

# Citer un package (ici ggplot2)
citation("ggplot2")

```

To cite ggplot2 in publications, please use

H. Wickham. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York, 2016.

Une entrée BibTeX pour les utilisateurs LaTeX est

```
@Book{,
  author = {Hadley Wickham},
  title = {ggplot2: Elegant Graphics for Data Analysis},
  publisher = {Springer-Verlag New York},
  year = {2016},
  isbn = {978-3-319-24277-4},
  url = {https://ggplot2.tidyverse.org},
}
```

1.4 🎮 À VOUS DE JOUER!

Exercice 1.1.

1. Vérifier que [R] et [RStudio] sont installés
2. Définir l'encodage UTF-8
3. Vérifier que le package {tidyverse} est installé et l'installer si ce n'est pas le cas

Quelle est la version de [R] et des packages {tidyverse} et {ggplot2} que vous utilisez ?

4. Sous [RStudio], créer un projet nommé **VisuR_exercices**
5. Créer les dossiers nécessaires pour une bonne structuration de votre travail
6. Déposer le fichier `communes.csv` dans le dossier adéquat de votre projet
7. Dans votre projet [RStudio], créer un script [R] nommé **01_Exercices_VisuR.R**, qui servira pour les exercices à venir, durant lesquels vous aurez besoin des packages {readr} et {dplyr}
8. Commencer l'écriture de ce script avec ces premiers éléments

Solution 1.1

Proposition de structuration du projet

```
VisuR_exercices/
├── data/
│   ├── sources/
│   │   └── communes.csv
│   └── produites/
├── scripts/
│   └── 01_Exercices_VisuR.R
├── figures/
├── results/
├── README.md
└── VisuR_exercices.Rproj
```

Script 01_Exercices_VisuR.R

```
# _____
# Script : Script pour les exercices "VisuR"
# Auteur : Sandrine Lyser
# Date   : 02 oct. 2026
# Dernière modification : sys.date()
# Text encoding : UTF-8
# R version : R version 4.6.0 (2026-04-24 ucrt) -- "Because it was There"
# _____

# _____
# Packages                                     #####

library(readr)    # v2.2.0
library(dplyr)    # v1.2.1
```

1.5 L'univers du tidyverse


1.5.1 Présentation générale et installation

- Ensemble de packages reprenant des opérations courantes de R, qui partagent une même philosophie et syntaxe pour travailler ensemble et faciliter, la manipulation, l'analyse et la visualisation des données
- L'accent est mis sur la lisibilité et la chaîne d'opérations, via l'opérateur *pipe* `|>`
 - » code dans l'ordre logique des étapes, moins d'objets intermédiaires et de parenthèses imbriquées que dans la syntaxe R de base

⚙️ La commande `install.packages("tidyverse")` installe simultanément plusieurs packages

- `dplyr` : manipulation des données
- `forcats` : traitement des variables qualitatives
- `ggplot2` : visualisation des données
- `lubridate` : manipulation des dates et heures
- `purrr` : programmation
- `readr` : import de données
- `stringr` : manipulation des chaînes de caractères
- `tibble` : version modernisée des *dataframes*, plus pratiques à utiliser que les *dataframes* "classiques"
- `tidyr` : nettoyage, remise en forme des données

💡 La commande `library("tidyverse")` charge simultanément ces neuf packages au coeur du tidyverse



1.5.1.1 L'opérateur *pipe*

- Opérateur qui permet d'enchaîner des opérations : il prend la sortie d'une fonction (ou d'une expression) et la passe automatiquement comme **premier** argument à la fonction suivante
- Initialement fourni dans le package `magrittr` et noté `%>%`
- Implémenté dans le langage R de base depuis la version 4.1.0 et noté `|>`

```
data |>
  fonction1() |>
  fonction2() |>
  fonction3()
```

```
# équivaut à
fonction3(fonction2(fonction1(data)))
```

💡 Il est recommandé d'utiliser le pipe natif de R | >

🔧 Comment utiliser le pipe natif sous RStudio ?

- Allez dans Tools > Global Options > Code > Editing
- Cochez Use native pipe operator, |> (requires R 4.1+)

1.5.1.2 Les *tibbles*

- **Version modernisée des *dataframes***, proposée dans le cadre du **tidyverse**
- Plus pratiques à utiliser que les *dataframes* "classiques"
- Plus rapides à manipuler (et plus stables) que les *dataframes*
- Il est possible de convertir d'un type à l'autre
 - *dataframe* → *tibble* : avec la fonction `as_tibble()` du package **tibble**
 - *tibble* → *dataframe* : avec la fonction **R** de base `as.data.frame()`

🔗 Pour connaître le type d'objet et savoir si on a un *dataframe* ou un *tibble*, on peut utiliser la fonction `str()`

Aperçu des formats

dataframe

```
Journals |>  
  head(2)
```

	title						pub	society
1	Asian-Pacific Economic Literature						Blackwell	no
2	South African Journal of Economic History So Afr ec history assn							no
	libprice	pages	charpp	citestot	date1	oclc	field	
1	123	440	3822	21	1986	14	General	
2	20	309	1782	22	1986	59	Ec History	

tibble

```
Journals |>  
  as_tibble() |>  
  head(2)
```

```
# A tibble: 2 x 10
  title      pub  society libprice pages charpp citestot date1  oclc field
<fct>      <fct> <fct>      <int> <int>  <int>    <int> <int> <int> <fct>
1 Asian-Pacific ~ Blac~ no      123   440   3822     21  1986    14 Gene~
2 South African ~ So A~ no       20   309   1782     22  1986    59 Ec H~
```

1.6 Manipulations des données

1.6.1 Import/Export des données

- Depuis/vers des formats “plats” ou délimités (.csv, .txt)
- Depuis/vers des fichiers Excel ou issus d’autres logiciels de statistique (Stata, SPSS, etc.)
- Depuis/vers des bases de données relationnelles

💡 Pour l'import, bien étudier le jeu de données source, à l'aide des questions suivantes

1. La première ligne contient-elle le nom des variables?
2. Quel est le séparateur des colonnes : , , ; , espace(s), \t?
3. Quel est le caractère utilisé pour indiquer les décimales : le point (à l'anglo-saxonne) ou la virgule (à la française)?
4. Les valeurs textuelles sont-elles encadrées par des guillemets? Si oui, s'agit-il de guillemets simples (') ou de guillemets doubles (")?
5. Y a-t-il des valeurs manquantes? Si oui, comment sont-elles indiquées?

1.6.1.1 Les fonctions d'import

Type de fichier	Séparateur de colonnes	Séparateur décimal	Tidyverse	Base R
Excel SPSS Stata SAS dBase	Délimité ,	.	<code>readr::read_csv()</code>	<code>read.csv()</code>
	;	,	<code>readr::read_csv2()</code>	<code>read.csv2()</code>
	un espace (ou plus)	.	<code>readr::read_table()</code>	<code>read.table()</code>
	\t	.	<code>readr::read_delim()</code>	<code>read.delim()</code>
	\t	,	<code>readr::read_delim2()</code>	<code>read.delim2()</code>
			<code>readxl::read_excel()</code>	<code>xlsx::read.xlsx()</code>
			<code>haven::read_spss()</code>	<code>foreign::read.spss()</code>
			<code>haven::read_sav()</code>	
			<code>haven::read_stata()</code>	<code>foreign::read.dta()</code>
			<code>haven::read_sas()</code>	<code>foreign::read.ssd()</code>
				<code>foreign::read.dbf()</code>

1.6.1.2 Les fonctions d'export

Type de fichier	Tidyverse	Base R
.txt	<code>readr::write_delim(delim = "\t")</code>	<code>write.table()</code>
.csv	<code>readr::write_csv()</code>	<code>write.csv()</code>
.xlsx	<code>openxlsx::write_xlsx()</code> <code>writexl::write_xlsx()</code>	
.dbf		<code>foreign::write.dbf()</code>
.sav (SPSS)	<code>haven::write_sav()</code>	<code>foreign::write.foreign(package = "SPSS")</code>
.dta (Stata)	<code>haven::write_dta()</code>	<code>foreign::write.dta()</code>

1.6.1.3 Exemple d'import pour un fichier .csv

```
readr::read_csv("file.csv"  
  # si la première ligne contient le nom des variables :  
  , col_names = TRUE)
```

💡 Zoom sur la fonction `read_csv2()`

La fonction `readr::read_csv2()` considère par défaut que le séparateur de colonnes est le point-virgule et que la virgule sert de séparateur décimal

La fonction en langage R de base `read.csv2()` a les mêmes paramètres par défaut

💡 **Utiliser ces fonctions lorsque les fichiers .csv ont ces caractéristiques**

1.6.2 Manipulations sur les observations et les variables avec le package `dplyr`

Principales fonctions utiles pour

- **les lignes/observations**
 - `filter()` : sélectionner/filtrer des observations
 - `distinct()` : afficher les observations distinctes
- **les colonnes/variables**
 - `select()` : sélectionner/extraire des variables
 - `mutate()` : créer des variables
 - `relocate()` : changer l'ordre d'une colonne
 - `rename()` : changer le nom des variables

i Aide-mémoire des principales fonctions du package `dplyr`

 [Cheatsheet](#)

1.6.2.1 Filtrer des observations avec la fonction `filter()`

1.6.2.1.1 Selon un seul critère

```
# Revues dans Le domaine de La Démographie
Journals |>
  dplyr::filter(field == "Demography")
```

		title	pub	society	libprice	pages
30		Journal of Population Economics	Springer	no	411	640
116		Population & Development Review	Population Council	no	36	910
137		Demography	Pop Assn America	no	85	568
	charpp	citestot	date1	oclc	field	
30	3264	69	1987	27	Demography	
116	2904	445	1975	218	Demography	
137	6859	670	1964	413	Demography	

1.6.2.1.2 Selon plusieurs critères

En utilisant les opérateurs logiques

```
# Revues de Démographie dont l'abonnement coûte moins de 100$
Journals |>
  dplyr::filter(field == "Demography" & libprice < 100)
```

		title	pub	society	libprice	pages
116		Population & Development Review	Population Council	no	36	910
137		Demography	Pop Assn America	no	85	568
	charpp	citestot	date1	oclc	field	
116	2904	445	1975	218	Demography	
137	6859	670	1964	413	Demography	

i Opérateurs logiques les plus courants

Opérateur	Description
<	Inférieur à
<=	Inférieur ou égal à
>	Supérieur à
>=	Supérieur ou égal à
==	Exactement égal à
!=	Différent de
	Ou
&	Et
%in%	Appartient à
is.na()	Est une donnée manquante
!is.na()	N'est pas une donnée manquante

1.6.2.2 Afficher les valeurs distinctes avec la fonction distinct()

On peut afficher les valeurs distinctes selon une (ou plusieurs) variables

```
# Afficher les valeurs distinctes de 'field'
```

```
Journals |>  
  distinct(field)
```

```
      field  
1      General  
2      Ec History  
3      Specialized  
4      Area Studies  
5      Interdisciplinary  
6      Labor  
7      Development  
11     Consumer Ec  
14     Management Science  
15     Finance  
25     Insurance  
28     Public Finance  
29     Urban and Regional  
30     Demography  
32     Ind Organization  
36     Business  
39     Econometrics  
40     Ag Econ  
45     Natural Resources  
57     Law and Econ  
58     International  
59     Macroeconomics  
84     Theory  
123     Health
```

💡 Cette fonction peut aussi servir à supprimer les doublons dans un jeu de données

1.6.2.3 Sélectionner des colonnes avec la fonction select()

1.6.2.3.1 Une seule colonne

```
# Sélection de la variable 'pub'
Journals |>
  dplyr::select(pub)
```

```
      pub
1 Blackwell
2 So Afr ec history assn
3 Kluwer
4 Kluwer
5 Elsevier
6 Elsevier
7 Cambridge Univ Pres
8 Elsevier
9 Kluwer
...
```

💡 On peut également utiliser la fonction `pull()` pour sélectionner une (et une seule) colonne

```
# Sélection de la variable 'pub'
Journals |>
  dplyr::pull(pub)
```

```
[1] Blackwell      So Afr ec history assn
[3] Kluwer          Kluwer
[5] Elsevier        Elsevier
[7] Cambridge Univ Pres Elsevier
[9] Kluwer          Blackwell
[11] Kluwer          MIT
[13] Blackwell       Wiley
[15] Elsevier        Springer
[17] MIT Press       Intl Atlantic Ec. Soc.
[19] Sage            Elsevier
...
```

- Quelle différence avec `select()` ?
Le format de sortie est différent :
 - la fonction `select()` renvoie la colonne sous forme de *dataframe*
 - la fonction `pull()` renvoie une colonne sous forme de vecteur

1.6.2.3.2 Plusieurs colonnes

En listant la/les variables à conserver

```
# Sélection des variables "field" et "libprice"
Journals |>
  dplyr::select(c(field, libprice))
```

```
      field libprice
1   General      123
2   Ec History      20
...
```

En listant la/les variables à supprimer

```
# Sélection des variables sauf "title" et "pub"
Journals |>
```

```
dplyr::select(-c(title, pub))
```

	society	libprice	pages	charpp	citestot	date1	oclc	field
1	no	123	440	3822	21	1986	14	General
2	no	20	309	1782	22	1986	59	Ec History
...								

💡 Les tests sur le nom des variables peuvent se faire avec différentes fonctions :

- contains()
- starts_with()
- ends_with()
- matches()

```
# Sélection des variables dont le nom contient "s"
Journals |>
  dplyr::select(contains("s"))
```

	society	pages	citestot
1	no	440	21
...			

1.6.2.4 Créer/ajouter de nouvelles variables avec mutate()

```
# Ajout de la variable 'anciennete'
Journals |>
  mutate(anciennete = 2026 - date1) -> Journals

names(Journals)
```

```
[1] "title"      "pub"        "society"    "libprice"   "pages"
[6] "charpp"     "citestot"   "date1"      "oclc"       "field"
[11] "anciennete"
```

⚠️ Penser à affecter la modification au jeu de données

- La fonction mutate() peut également
 - modifier une variable existante si le nom est le même que celui d'une colonne existante
 - supprimer une variable en fixant sa valeur à NULL

```
# Suppression de la variable 'charpp'
Journals |>
  mutate(charpp = NULL) |>
  names()
```

```
[1] "title"      "pub"        "society"    "libprice"   "pages"
[6] "citestot"   "date1"      "oclc"       "field"      "anciennete"
```

1.6.2.4.1 Appliquer des règles conditionnelles

La fonction if_else()

```
Journals |>
  mutate(cl_anciennete = if_else(anciennete < 30, " Moins de 30 ans",
                                if_else(anciennete >= 30 & anciennete < 50, "30 à 49 ans",
```

```

if_else(anciennete >= 50 & anciennete < 100, "50 à
↪ 99 ans",
        if_else(anciennete >= 100 & anciennete <
↪ 150,
                "100 à 149 ans", "150 ans et
↪ plus")))) -> Journals

```

La fonction `case_when()`

```

Journals |>
mutate(cl_anciennete = case_when(anciennete < 30 ~ "Moins de 30 ans",
                                anciennete >= 30 & anciennete < 50 ~ "30 à 49 ans",
                                anciennete >= 50 & anciennete < 100 ~ "50 à 99 ans",
                                anciennete >= 100 & age < 150 ~ "100 à 149 ans",
                                anciennete >= 150 ~ "150 ans et plus",
                                TRUE ~ "ERREUR")) -> Journals

```

1.6.2.5 Réordonner les variables avec la fonction `relocate()`

💡 Les nouvelles variables ajoutées avec `mutate()` se positionnent toujours à la fin du jeu de données

» Il est possible de les positionner où l'on souhaite, avec la fonction `relocate()`

```

# On repositionne la variable 'anciennete' après la variable 'date1'
Journals |>
relocate(anciennete, .after = date1) -> Journals

# Vérification
Journals |>
names()

```

```

[1] "title"      "pub"        "society"    "libprice"   "pages"
[6] "charpp"     "citestot"   "date1"      "anciennete" "oclc"
[11] "field"

```

On aurait également pu obtenir le même résultat avec le paramètre `.before`

```

Journals |>
relocate(anciennete, .before = oclc) -> Journals

```

1.6.2.6 Modification du nom des colonnes avec `rename()`

```

# On renomme la colonne 'pub' en 'publisher'
Journals |>
dplyr::rename(publisher = pub) -> Journals

# Vérification : affichage du nom des colonnes
Journals |>
names()

```

```

[1] "title"      "publisher"  "society"    "libprice"   "pages"
[6] "charpp"     "citestot"   "date1"      "anciennete" "oclc"
[11] "field"

```

⚠ Ne pas oublier d'affecter la modification au jeu de données

1.7 🎮 À VOUS DE JOUER!

Exercice 1.2. On se place toujours dans le projet **VisuR_exercices** et le fichier *01_Exercices_VisuR.R*, et on utilise les fonctions du tidyverse

1. Importer les données du fichier `communes.csv` dans un objet `communes`
2. Quel est le type de cet objet et sa structure (nombre de lignes et de colonnes)?
3. La variable `CODGEO` est un code. Transformer en variable caractère avec la fonction `as.character()`
4. Combien de communes distinctes y a-t-il dans `communes`? et combien d'années?
5. Filtrer les données pour n'afficher que les observations de l'année 2018
6. Créer la variable `surface = surface_urbaine + surface_verte` dans votre jeu de données. Elle doit se trouver avant la variable `surface_urbaine`
7. Afficher la colonne commune et toutes celles qui commencent par "surface_"

Solution 1.2. Ces commandes sont à écrire dans le script *01_Exercices_VisuR.R* créé dans l'exercice 1.

```
# _____ #####
# 01. Import des données

# Le fichier csv est dans le dossier 'data'
# Les colonnes sont séparées par un ';' et les décimales par une ',' -> on peut utiliser
# read_csv2
readr::read_csv2("data/communes.csv") -> communes

# _____ #####
# 02. Type et structure de 'communes'

class(communes)
# ==> L'objet 'communes' est de type tibble. Il contient 84 lignes et 16 colonnes

# _____ #####
# 03. Transformer la variable `CODGEO` en variable caractères

communes <- communes |>
  mutate(CODGEO = as.character(CODGEO))

# _____ #####
# 04. Nombre de communes et d'années distinctes

communes |>
  distinct(commune)
# ==> Il y a 28 communes différentes

communes |>
  distinct(annee)
# ==> Il y a trois années différentes : 2018, 2020 et 2022

# _____ #####
# 05. Affichage des observations de l'année 2018

communes |>
  filter(annee == 2018)
# ==> Si l'on filtre les observations de l'année 2018, on n'affiche que 28 observations

# _____ #####
# 06. Création de la variable 'surface'

communes <- communes |>
  mutate(surface = surface_urbaine + surface_verte) |>
```

```
# positionnement avant la variable 'surface_urbaine'
relocate(surface, .before = surface_urbaine)

# -----
# 07. Affichage de la colonne 'commune' et des colonnes "surface_" #####
communes |>
  select(commune, starts_with("surface_"))
```

2 Séance 2. Premiers graphiques avec {ggplot2}

2.1 Objectifs pédagogiques

À l'issue de cette séance, vous serez capable de

- comprendre la logique de {ggplot2}
- transformer les données dans un format adapté pour les graphiques

2.2 Visualisations graphiques avec {ggplot2}

2.2.1 Le package {ggplot2}

Ce package produit des graphiques en utilisant une grammaire particulière (*grammar of graphics*)

— Installation

```
install.packages("ggplot2")
```

— Chargement

```
library(ggplot2)
```

— Création d'un graphique

Le principe consiste à initialiser un graphique avec la commande `ggplot()` puis à ajouter des couches permettant de représenter les données et mettre en forme le graphique


```
ggplot(data = dataframe,
       aes = (x, y)) +
  ...
```

Voir le site <https://r-charts.com/ggplot2/> pour une galerie de graphiques.

- i** Le système de création des graphiques est basé sur *The Grammar of Graphics* (Wilkinson, 1999, 2005)
- **L'idée est de décomposer la construction d'un graphique en plusieurs éléments, que l'on appelle *layers* (couches, en français)**

2.2.2 La grammaire ggplot

Une structure en 7 *layers* superposables




Source : [ThinkR \(2016\)](#)

i A minima: un graphique = data + aesthetics + geometries
 Les quatre autres *layers* permettent de paramétrer plus finement le graphique

2.2.3 Construction d'un graphique, couche par couche


1. On initialise le graphique par `ggplot()` puis on associe les données (*dataframe* ou *tibble*) avec `data` et les attributs esthétiques avec `aes()`

```
ggplot(data = Journals) +  
  aes(x = oclc, y = libprice)
```



- ! À ce stade, on visualise le canevas du graphique mais les données ne sont pas encore représentées**
2. On ajoute une couche de géométrie pour dessiner les données (= type de graphique)

```
# Nuage de points avec geom_point  
ggplot(data = Journals) +  
  aes(x = oclc, y = libprice) +  
  geom_point()
```



» Avec `geom_*()`, les données sont représentées sur le graphique

3. On ajoute ensuite des couches pour ajuster la mise en forme du graphique

2.2.3.1 `aes()` : définir les paramètres esthétiques

On précise quelles variables contrôlent les propriétés visuelles du graphique

<i>Aesthetic</i>	Description
x	variable en abscisse
y	variable en ordonnée
colour	couleur du contour (des points, lignes, etc.)
fill	couleur de remplissage (des points, formes, etc.)
size	taille des points, épaisseur des lignes
alpha	transparence
linetype	motif des tirets des lignes
shape	type de formes

2.2.3.2 `geom_*()` : définir le type de graphique

Principales géométries

TABEAU 1. Les aspects esthétiques obligatoires sont indiqués en gras

Geometry	Description	Aspects esthétiques
<code>geom_point()</code>	Nuage de points	x, y , colour, fill, group, shape, size, alpha
<code>geom_bar()</code>	Diagramme en barres	x, y , colour, fill, group, linetype, linewidth, alpha
<code>geom_histogram()</code>	Histogramme	<i>identiques à <code>geom_bar()</code></i>
<code>geom_boxplot()</code>	Boîte à moustaches	x OU y , ymin OU xmin , ymax OU xmax , colour, fill, group, linetype, linewidth, shape, size, alpha
<code>geom_density()</code>	Densité	x, y , colour, fill, group, linetype, linewidth, alpha
<code>geom_line()</code>	Courbe	x, y , colour, group, linetype, linewidth, alpha
<code>geom_text()</code>	Texte	x, y , label, colour, angle, group, hjust, lineheight, size, vjust, alpha
<code>geom_label()</code>	Texte	<i>identiques à <code>geom_text()</code> + fill</i>

💡 Possibilité d'ajouter plusieurs fonctions `geom_*()` sur un même graphique

i  L'ensemble des fonctions `geom_*` est détaillé dans la *cheatsheet* [ggplot2]


- version 
- version 

💡 Une règle simple à retenir


- **Ce qui se trouve dans `aes()` varie avec les données** = une variable détermine une esthétique
- **Les esthétiques placées en dehors de `aes()`, dans `geom_*()`, correspondent à un réglage fixe** = une valeur fixe règle l'apparence de la couche `geom_*()`

Exemples

```
# Points colorés selon les valeurs de "society"
ggplot(data = Journals) +
  aes(x = oclc, y = libprice,
      colour = society) +
  geom_point()
```



```
# Points de couleur verte"
ggplot(data = Journals) +
  aes(x = oclc, y = libprice) +
  geom_point(color = "#275662")
```



2.2.3.3 stat_*() : effectuer un calcul sur les données avant leur affichage

» Ce qui est affiché sur le graphique : comptage, moyenne, etc.


Principales fonctions

Fonctions	Description
stat_identity()	Données brutes, sans transformation
stat_count()	Comptage par modalité d'une variable catégorielle

Fonctions	Description
stats_bin()	Découpage d'une variable continue en classes (<i>bins</i>)
stat_summary()	Résumé d'une variable pour chaque modalité d'une autre variable
stats_boxplot()	Calcul des statistiques de la boîte à moustaches (médiane, quartiles, moustaches)
stats_sum()	Comptage de points superposés

Exemple

```
# Affichage sur chaque boxplot
# de la moyenne de 'libprice'
ggplot(data = Journals) +
  aes(x = society, y = libprice) +
  geom_boxplot() +
  stat_summary(geom = "point",
               fun = "mean",
               colour = "#A626A4",
               shape = 17,
               size = 4)
```




2.2.3.4 Équivalences entre geom_*() et stat_*()

Les deux sont souvent interchangeables, c'est une différence de point de vue : geom_*() priorise la forme graphique (barres, points, lignes); stat_*() priorise la transformation statistique (comptage, résumé, etc.)

» On peut reproduire le graphique précédent avec geom_point()

```
ggplot(data = Journals) +
  aes(x = society, y = libprice) +
  geom_boxplot() +
  geom_point(stat = "summary",
            fun = "mean",
            colour = "#A626A4", shape = 17, size = 4)
```



Principales correspondances

<i>Geometry</i>	<i>Statistics</i>
<code>geom_bar()</code>	<code>stat_count()</code>
<code>geom_histogram()</code>	<code>stat_bin()</code>
<code>geom_boxplot()</code>	<code>stat_boxplot()</code>
<code>geom_density()</code>	<code>stat_density()</code>
<code>geom_quantile()</code>	<code>stat_quantile()</code>
<code>geom_count()</code>	<code>stat_sum()</code>
<code>geom_dotplot()</code>	<code>stat_bindot()</code>

2.2.4 Éléments de personnalisation des graphiques pour faciliter leur lecture

- `scale_...()` : modifier les attributs liés
 - aux axes (échelles, limites, titre, format des chiffres par exemple)
 - aux données représentées (couleurs, etc.)
- `ggtitle()` : ajouter ou modifier uniquement le titre principal du graphique
- `xlab()` : modifier uniquement l'intitulé de l'axe des abscisses
- `ylab()` : modifier uniquement l'intitulé de l'axe des ordonnées
- `labs(title = ..., subtitle = ..., caption = ..., x = ..., y = ...)` : modifier plusieurs étiquettes (titre, sous-titre, légende, axes) en une seule commande

💡 Les fonctions `ggtitle()`, `xlab()`, `ylab()` sont pratiques pour de petits ajouts rapides
La fonction `labs()` offre plusieurs options de personnalisation des titres et labels, en une seule commande

💡 Si certains éléments peuvent être omis pour épurer le graphique sans nuire à sa compréhension (axe des abscisses, cadre, 3D), il est conseillé de faire commencer l'axe des ordonnées à 0



FIGURE 1. Les épaisseurs de lignes



FIGURE 2. Les types de lignes




FIGURE 3. Les symboles de points




FIGURE 4. Les couleurs (package [RColorBrewer](#))

💡 Aide pour le choix des couleurs

— Packages

- 📦 [\[paletteer\]](#) : recense des milliers de palettes (2893) issues de packages différents (79)
- 📦 [\[cols4all\]](#) : une application Shiny pour explorer les palettes, accessibles pour tous, y compris les personnes souffrant d'un déficit de vision des couleurs

```
cols4all::c4a_gui()
```

— Sites


- 🌐 Informations sur une couleur : <https://chir.ag/projects/name-that-color/>
- 🌐 Un générateur de palettes de couleurs : <https://colors.co/>
- 🌐 Des palettes de couleurs prédéfinies : <https://flatuicolors.com/>
- 🌐 Des palettes de couleurs pour la cartographie : <http://colorbrewer2.org>

2.2.5 Exemples de graphiques de base avec [ggplot2](#)

2.2.5.1 Histogramme

```
# Histogramme du nombre total de citations ("citestot")
ggplot(data = Journals) +
  aes(x = citestot) +
  geom_histogram(bins = 10, # nb de barres (30 par défaut)
                 fill = "skyblue", # remplissage des barres
                 color = "black") + # couleur de la bordure
  # Ajout du titre et des labels
  labs(title = "Histogramme du nombre total de citations",
       x = "citestot",
       y = "Effectif")
```


Histogramme du nombre total de citations



2.2.5.2 Boxplot

```
# Boxplot du nombre total de citations ("citestot")
# selon l'appartenance à une société ("society")
ggplot(data = Journals) +
  aes(x = society, y = citestot) +
  geom_boxplot(fill = "purple") + # couleur des boîtes
  # Ajout du titre et des labels
  labs(title = "Boxplot du nombre de citations
             selon l'appartenance à une société",
        x = "society",
        y = "citestot")
```


Boxplot du nombre de citations
selon l'appartenance à une société



2.2.5.3 Diagramme en barres

```
# Barplot du nombre de revues
# selon l'appartenance à une société ("society")
ggplot(data = Journals) +
  aes(x = society) +
  geom_bar(fill = "#00a3a6") + # couleur des barres
# Ajout du titre et des labels
  labs(title = "Barplot du nombre de revues
            selon l'appartenance à une société",
        x = "society",
        y = "Nombre")
```

Barplot du nombre de revues
selon l'appartenance à une société



2.2.6 Exemple de mise en forme plus avancée d'un graphique avec `ggplot2`

```
ggplot(data = Journals) +      # initialisation du graphique
  aes(x = oclc,                # variable en abscisse
      y = libprice,           # variable en ordonnée
      colour = society) +     # points colorés selon les valeurs de "society"
  geom_point(shape = 1,       # type de symbole
             size = 1.5,     # taille des symboles
             stroke = 1.5) + # épaisseur de la bordure des symboles
  scale_x_continuous(limits = c(0, 1000)) + # limites de l'axe des x
  scale_y_continuous(limits = c(0, 2500),   # limites de l'axe des y
                    breaks = seq(from = 0, to = 2500, by = 500)) + # graduations de l'axe
  # des y
  labs(title = "Exemple de création d'un graphique {ggplot2}", # titre du graphique
       subtitle = "Nuage de points du prix de l'abonnement
                  selon le nombre d'abonnements", # sous-titre
       x = "Nombre d'abonnements", # titre pour l'axe des x
       y = "Prix de l'abonnement", # titre pour l'axe des y
       caption = "Les points sont colorés selon l'appartenance à une société") # légende
```

Exemple de création d'un graphique {ggplot2}

Nuage de points du prix de l'abonnement
selon le nombre d'abonnements



Les points sont colorés selon l'appartenance à une société

2.2.7 Sauvegarde des graphiques créés avec `ggplot2`

- Utilisation de la fonction `ggsave()` du package `ggplot2` à la fin de la création du graphique pour l'enregistrer

```
# Sauvegarde du graphique
ggplot(...) +
  ...
ggsave(filename = name.extension,
       device = NULL)
```

💡 Les formats d'enregistrement possibles

- png
- jpeg
- tiff
- bmp
- svg
- eps
- ps
- pdf
- tex

i


- Le format du graphique peut être précisé dans le paramètre `device`
Si `device = NULL`, le type de graphique est déterminé automatiquement en fonction de l'extension du nom du fichier
- La taille (`width` et `height`), ainsi que la résolution (`dpi`) peuvent être paramétrées

2.2.8 Vous n'êtes pas à l'aise pour réaliser un graphique `ggplot2` ?

Une interface "clic bouton", avec la possibilité de récupérer les lignes de code, peut vous aider  [\[esquisse\]](#)

- Commande pour lancer [\[esquisse\]](#)

esquisse::esquisser()



2.2.9 Un site pour aider à trouver la représentation la plus appropriée aux données

Voir le site [from Data to Viz](#)

2.3 🎮 À VOUS DE JOUER!

Exercice 2.1. Construire des graphiques avec {ggplot2} à partir du jeu de données communes

Compléter le script `01_Exercices_Visur.R` du projet `Visur_exercices` pour créer les graphiques suivants :

1. un diagramme en barres pour visualiser la distribution de la variable 'region'
Pour ce graphique on choisit de colorer les barres en bleu
2. un histogramme pour visualiser la distribution de la variable de surface_urbaine pour l'année 2020
Choisir un nombre ou une largeur de classes pertinents pour pouvoir interpréter le graphique
3. un boxplot du taux de chômage selon l'année
Pour ce graphique, on choisit de colorer les boîtes en fonction de l'année
4. Sauvegarder ce graphique dans le dossier adéquat, en png

Les graphiques doivent comporter toutes les informations utiles (étiquettes) pour faciliter leur compréhension

3 Bibliographie

Références citées

- Orozco, V., Bontemps, C., Maigné, E., Piguet, V., Hofstetter, A., Lacroix, A., Levert, F., & Rousselle, J.-M. (2020). How To Make A Pie : Reproducible Research for Empirical Economics and Econometrics. *Journal of Economic Surveys*, 34(5), 11341169. <https://doi.org/10.1111/joes.12389>
- Wilkinson, L. (1999). *The Grammar of Graphics* (1st éd.). Springer New York, NY. <https://doi.org/10.1007/978-1-4757-3100-2>
- Wilkinson, L. (2005). *The Grammar of Graphics* (2nd éd.). Springer New York, NY. <https://doi.org/10.1007/0-387-28695-0>

Packages

- Bache, S. M., & Wickham, H. (2026). *magrittr : A Forward-Pipe Operator for R*. <https://magrittr.tidyverse.org>
- Barbone, J. M., & Garbuszus, J. M. (2026). *openxlsx2 : Read, Write and Edit xlsx Files*. <https://janmarvin.github.io/openxlsx2/>
- Barnier, J., Briatte, F., & Larmarange, J. (2026). *questionr : Functions to Make Surveys Processing Easier*. <https://juba.github.io/questionr/>
- Croissant, Y., & Graves, S. (2025). *Ecdat : Data Sets for Econometrics*. <https://www.r-project.org>
- Csárdi, G., Hester, J., Wickham, H., Chang, W., Morgan, M., & Tenenbaum, D. (2024). *remotes : R Package Installation from Remote Repositories, Including GitHub*. <https://remotes.r-lib.org>
- Dragulescu, A., & Arendt, C. (2020). *xlsx : Read, Write, Format Excel 2007 and Excel 97/2000/XP/2003 Files*. <https://github.com/colearendt/xlsx>
- Grolemund, G., & Wickham, H. (2011). Dates and Times Made Easy with lubridate. *Journal of Statistical Software*, 40(3), 125. <https://www.jstatsoft.org/v40/i03/>
- Hester, J., Angly, F., Chirico, M., Hyde, R., Kun, R., Patil, I., & Rosenstock, A. (2025). Static Code Analysis for R. *Journal of Open Source Software*, 10(108), 7240. <https://doi.org/10.21105/joss.07240>
- Hester, J., Angly, F., Hyde, R., Chirico, M., Ren, K., Rosenstock, A., Patil, I., Gruson, H., & Ferdman, E. (2026). *lintr : A Linter for R Code*. <https://lintr.r-lib.org>
- Müller, K., Walthert, L., & Patil, I. (2025). *styler : Non-Invasive Pretty Printing of R Code*. <https://github.com/r-lib/styler>
- Müller, K., & Wickham, H. (2026). *tibble : Simple Data Frames*. <https://tibble.tidyverse.org/>
- Ooms, J. (2025). *writexl : Export Data Frames to Excel xlsx Format*. <https://ropensci.r-universe.dev/writexl>
- R Core Team. (2026). *foreign : Read Data Stored by Minitab, S, SAS, SPSS, Stata, Systat, Weka, dBase, ...* <https://svn.r-project.org/R-packages/trunk/foreign/>
- Spinu, V., Grolemund, G., & Wickham, H. (2026). *lubridate : Make Dealing with Dates a Little Easier*. <https://lubridate.tidyverse.org>
- Walthert, L. (2026). *strcode : Structure and abstract your code*. <https://github.com/lorenzwalther/strcode>
- Wickham, H. (2016). *ggplot2 : Elegant Graphics for Data Analysis*. Springer-Verlag New York. <https://ggplot2.tidyverse.org>
- Wickham, H. (2023). *tidyverse : Easily Install and Load the Tidyverse*. <https://tidyverse.tidyverse.org>
- Wickham, H. (2025a). *forcats : Tools for Working with Categorical Variables (Factors)*. <https://forcats.tidyverse.org/>
- Wickham, H. (2025b). *stringr : Simple, Consistent Wrappers for Common String Operations*. <https://stringr.tidyverse.org>
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., ... Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- Wickham, H., & Bryan, J. (2026). *readxl : Read Excel Files*. <https://readxl.tidyverse.org>
- Wickham, H., Chang, W., Henry, L., Pedersen, T. L., Takahashi, K., Wilke, C., Woo, K., Yutani, H., Dunnington, D., & van den Brand, T. (2026). *ggplot2 : Create Elegant Data Visualisations Using the Grammar of Graphics*. <https://ggplot2.tidyverse.org>
- Wickham, H., François, R., Henry, L., Müller, K., & Vaughan, D. (2026). *dplyr : A Grammar of Data Manipulation*. <https://dplyr.tidyverse.org>
- Wickham, H., & Henry, L. (2026). *purrr : Functional Programming Tools*. <https://purrr.tidyverse.org/>
- Wickham, H., Hester, J., & Bryan, J. (2026). *readr : Read Rectangular Text Data*. <https://readr.tidyverse.org>
- Wickham, H., Miller, E., & Smith, D. (2025). *haven : Import and Export SPSS, Stata and SAS Files*. <https://haven.tidyverse.org>
- Wickham, H., Vaughan, D., & Girlich, M. (2025). *tidyr : Tidy Messy Data*. <https://tidyr.tidyverse.org>